Empezando en R

David Hoyos

Universidad del País Vasco (UPV/EHU) Spain

febrero 17, 2020

¿Por qué R?

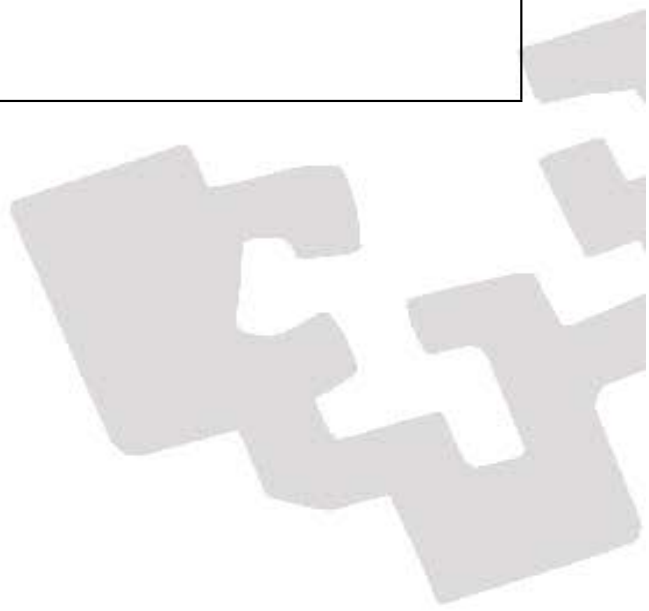

Software para análisis de datos

Software comercial

- **Nlogit** es una extensión del programa de estadística LIMDEP (variables dependientes limitadas)
- **STATA** es un paquete de estadística y análisis de datos
- **LATENT GOLD** es un programa especializado en clases latentes
- **Lenguajes de programación**: Ox (computación paralela), GAUSS, Mathlab

Software de código abierto:

- **R** (AER package, [AER package], Applied Econometrics with R)
- **Python-Biogeme**, **Panda-Biogeme**
- **Ox** Consola (gratis para educación e investigación)

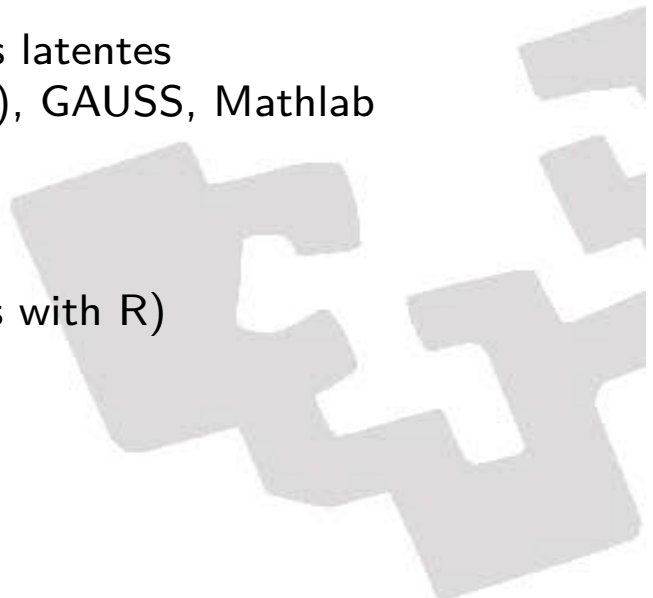

R

- **R** es un lenguaje y entorno para análisis estadístico y gráficos
- Está disponible como **Software Libre** en forma de código abierto
- Compila y funciona en una gran variedad de plataformas **UNIX** y sistemas similares como **Windows** y **MacOS**

Puntos fuertes (P. Dalgaard, R, Core Team) :

- Expresión compacta de idea, en una línea
- Fácil construcción de estudios de simulación
- Operaciones con objetos de un modelo (e.g. predicción en datos nuevos)
- Sistema gráfico flexible

Programas dirigidos con menús

El problema es que R puede ser difícil de aprender, pero ¿qué pasa con los programas comerciales que funcionan con menús?

Utilizar paquetes de este tipo puede tener también pros y contras.

En general:

Pros

- fácil de estimar modelos muy complejos
- bajo esfuerzo para escribir códigos
- coste de aprendizaje bajo

Contras

- a veces el analista no entiende lo que realmente está sucediendo en el proceso de estimación del modelo (black box)
- el analista sólo puede estimar los modelos que vienen incluidos en el programa


Sean J. Taylor: The Statis
seanjtaylor.com/post/39573264781/the-statistics-software-signal
Apps
Google Keep
Google logo
Calendario
Traductor de Google
Gmail
Contactos Gmail
sean j. taylor
computational social scientist
about cv faq facebook
twitter instagram
The Statistics Software Signal
Last night on Twitter, I went on a bit of a rant about statistics packages (namely Stata and SPSS). My point was not that these software packages are bad per se, but that I have found them to be correlated with bad quality science. Here is my theory why.
1. When you don't have to code your own estimators, you probably won't understand what you're doing. I'm not saying that you definitely won't, but push-button analyses make it easy to compute numbers that you are not equipped to interpret.
2. When it's extremely low cost to perform inference, you are likely to perform a lot of inferences. When your first regression gives a non-result, you run a second one, and a third one, etc. This leads untrained researchers to run into multiple comparisons problems and increases the risk of Type I errors.
3. When operating software doesn't require a lot of training, users of that software are likely to be poorly trained. This is an adverse selection issue. Researchers who care about statistics enough should have gravitated toward R at some point. I also trust results produced using R, not because it is better software, but because it is difficult to learn. The software is not causing you to be a better scientist, but better scientists will be using it.
4. When you use proprietary software, you are sending the message that you don't care about whether people can replicate your analyses or verify that the code was

¿Por qué R?

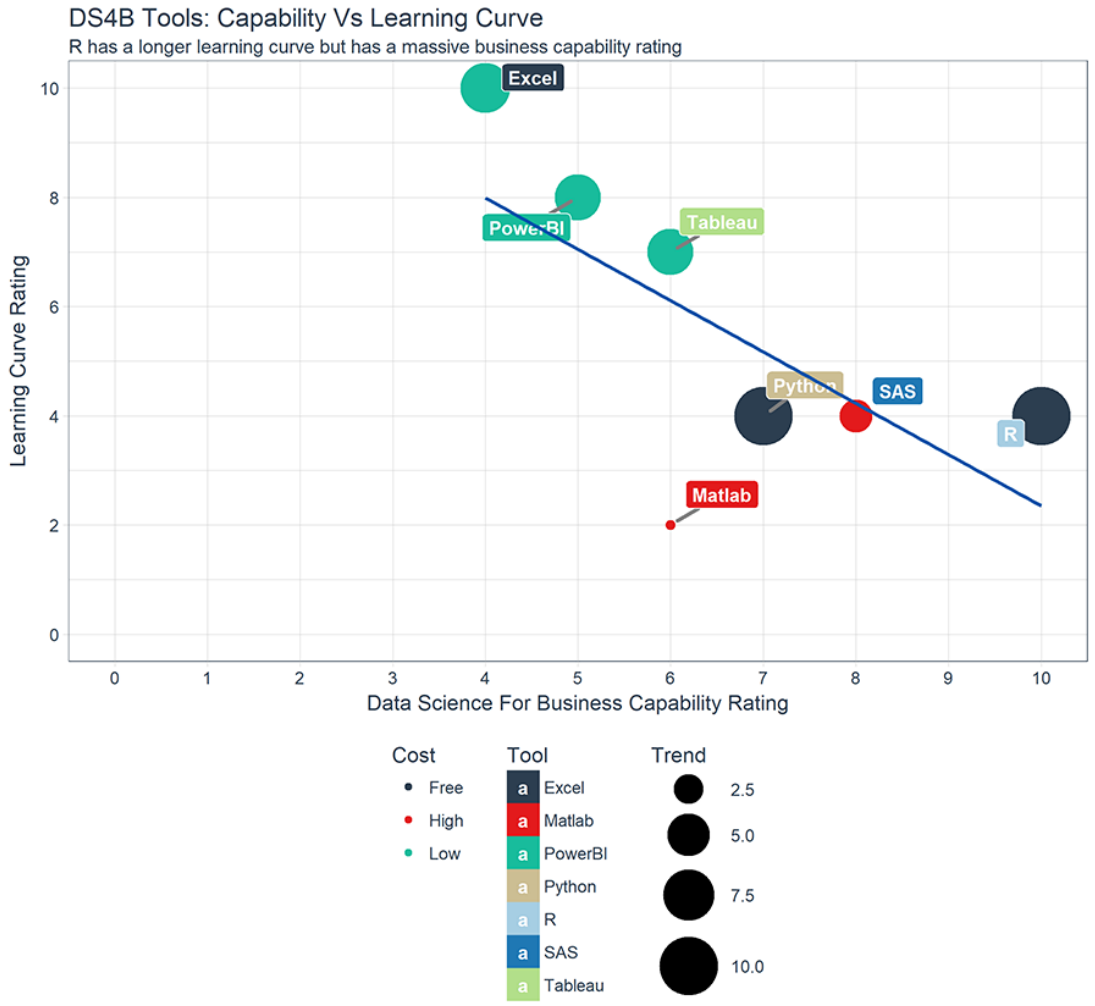

Source: https://www.business-science.io/business/2017/12/27/six-reasons-to-use-R-for-business.html

¿Por qué R?

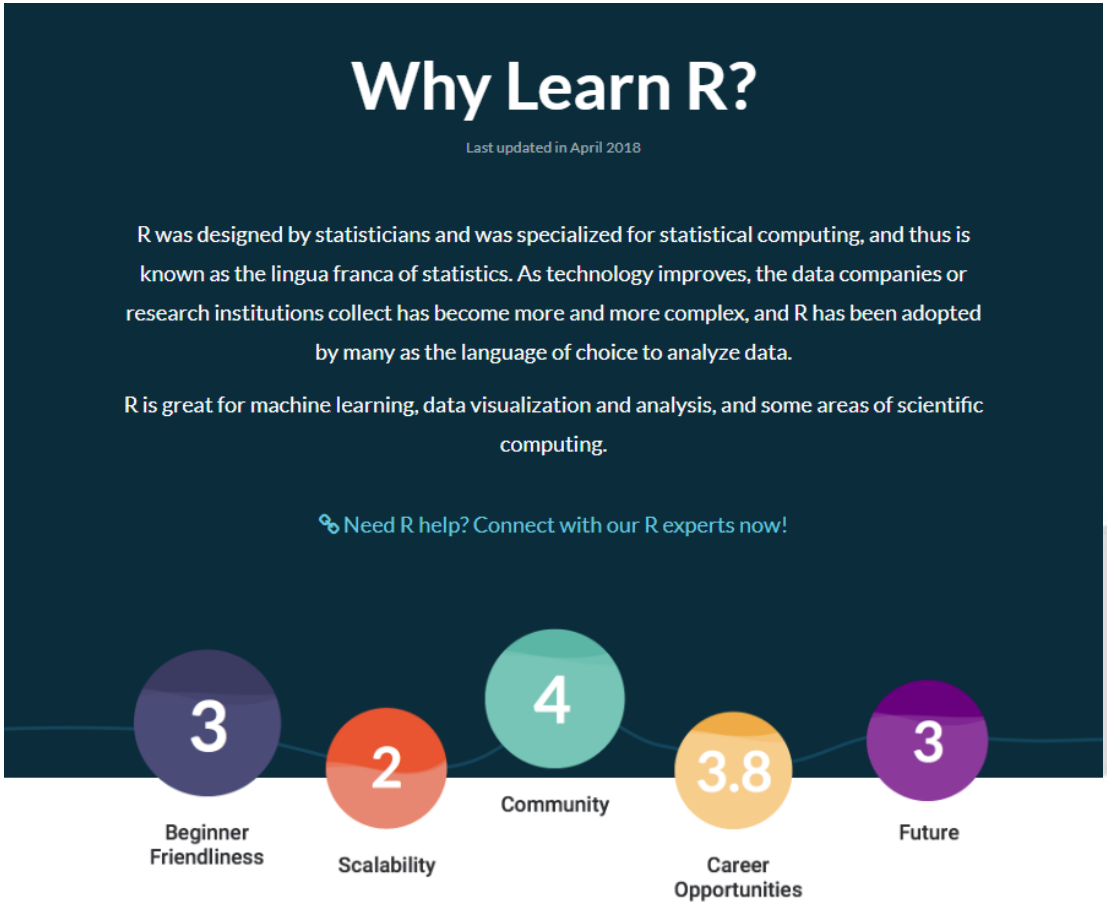

Source: http://www.bestprogramminglanguagefor.me/why-learn-r

Conceptos básicos

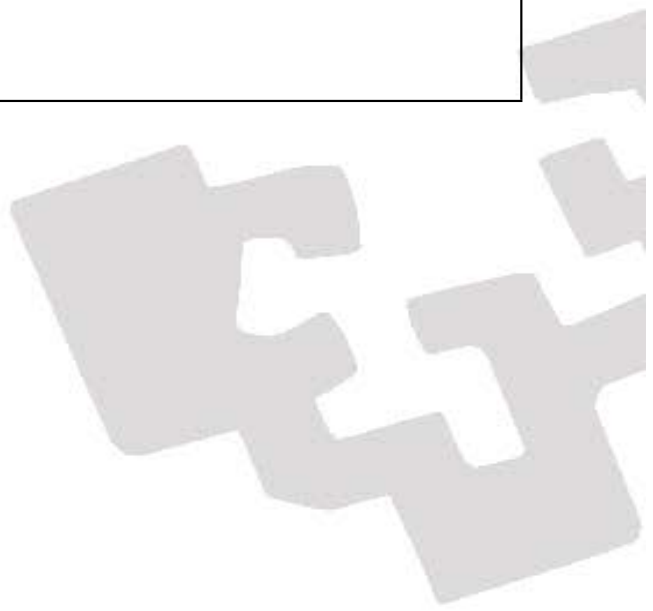

Conceptos básicos

Eliminar todos los objetos de la memoria

```
rm(list = ls(all = TRUE))
```

Diferentes tipos de variables que vamos a utilizar

```
A <- 10
B <- "Computer"
C <- TRUE
```

```
mode(A)
```

```
[1] "numeric"
```

```
mode(B)
```

```
[1] "character"
```

```
mode(C)
```

```
[1] "logical"
```

Conceptos básicos

Es habitual empezar los scripts de R con el espacio de trabajo vacío

```
# Preliminares
rm(list = ls(all = TRUE))              # Limpia el espacio de trabajo
Sys.setenv(LANG = "en")                # Elegir idioma
setwd(".")                             # Elegir directorio de trabajo
```

Conceptos básicos

R es sensible a las mayúsculas, "Index" y "index" son dos variables diferentes

```
index <- 1
Index <- 10

index
```

```
[1] 1
```

```
Index
```

```
[1] 10
```

Guía de estilo de R de Google

En https://google.github.io/styleguide/Rguide.xml puedes encontrar una guía de cómo hacer tus códigos comprensibles y fáciles de leer. La Guía de Estilo de R de Google recomienda, por ejemplo:

Calidad del nombre	*Nombre de la variable*
Good	avg.clicks
Acceptable	avgClicks
Bad	avg_Clicks

Vectores

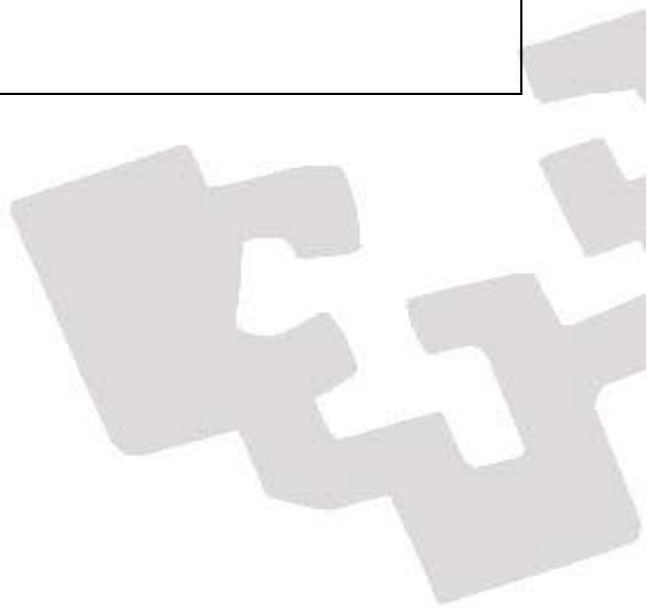

Vectores

Definicion de vectores

```
x <- vector(mode = "numeric",
            length = 4)
x
```

```
[1] 0 0 0 0
```

```
xlog <- vector(mode = "logical",
               length = 3)
xlog
```

```
[1] FALSE FALSE FALSE
```

Acceso a elementos de un vector

```
x[1] <- 1
x
```

```
[1] 1 0 0 0
```

```
xlog[3] <- TRUE
xlog
```

```
[1] FALSE FALSE  TRUE
```

Definición alternativa de un vector

Replicar

```
rep(5,3)
```

```
[1] 5 5 5
```

```
rep(10,6)
```

```
[1] 10 10 10 10 10 10
```

Combinar

```
c(1,2,3,4)
```

```
[1] 1 2 3 4
```

```
c(3,5,1,-8,7,6,0)/2
```

```
[1]  1.5  2.5  0.5 -4.0  3.5  3.0  0.0
```

Combinar comandos

```
rep(c(1,2,3,4),3)
```

```
 [1] 1 2 3 4 1 2 3 4 1 2 3 4
```

```
rep(c(3,5,1,-8,7,6,0)/2,2)
```

```
 [1]  1.5  2.5  0.5 -4.0  3.5  3.0  0.0  1.5  2.5  0.5 -4.0  3.5  3.0  0.0
```

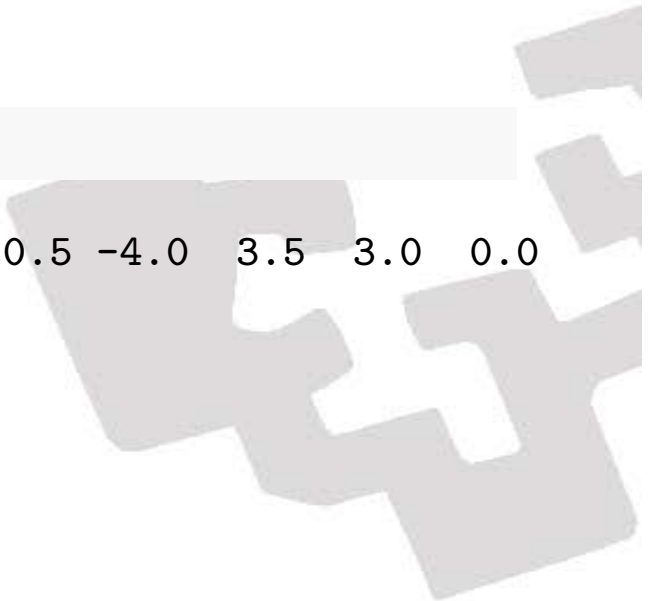

Definición alternativa de un vector: secuencias

Definición de secuencias

```
z1 <- 1:4
z1
```

```
[1] 1 2 3 4
```

```
z2 <- seq(1:4)
z2
```

```
[1] 1 2 3 4
```

```
z3 <- seq(2, 8, by=2)
z3
```

```
[1] 2 4 6 8
```

```
z4 <- seq(0,10,length=7)
z4
```

```
[1]  0.000000  1.666667  3.333333  5.000000  6.666667  8.333333 10.000000
```

Comparaciones y operadores lógicos

Comparaciones básicas

```
1 == 2
```

```
[1] FALSE
```

```
1 != 2
```

```
[1] TRUE
```

```
1 <= 2
```

```
[1] TRUE
```

```
1 > 2
```

```
[1] FALSE
```

Operadores lógicos básicos

```
(1 == 2) & (1 < 2)
```

```
[1] FALSE
```

```
(1 == 2) | (1 < 2)
```

```
[1] TRUE
```

```
! c((1 == 2), 1 < 2)
```

```
[1]  TRUE FALSE
```

```
x <- c(1,2,3,4,5,6)
x
```

```
[1] 1 2 3 4 5 6
```

Funciones internas básicas I

```
sum(x)
```

```
[1] 21
```

```
prod(x)
```

```
[1] 720
```

```
max(x)
```

```
[1] 6
```

```
min(x)
```

```
[1] 1
```

```
which.max(x)
```

```
[1] 6
```

```
which.min(x)
```

```
[1] 1
```

Funciones internas básicas II

```
x
```

```
[1] 1 2 3 4 5 6
```

```
range(x)
```

```
[1] 1 6
```

```
length(x)
```

```
[1] 6
```

```
mean(x)
```

```
[1] 3.5
```

```
median(x)
```

```
[1] 3.5
```

```
x
```

```
[1] 1 2 3 4 5 6
```

```
var(x)
```

```
[1] 3.5
```

```
cumsum(x)
```

```
[1]  1  3  6 10 15 21
```

```
summary(x)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   1.00    2.25    3.50    3.50    4.75    6.00
```

Matrices

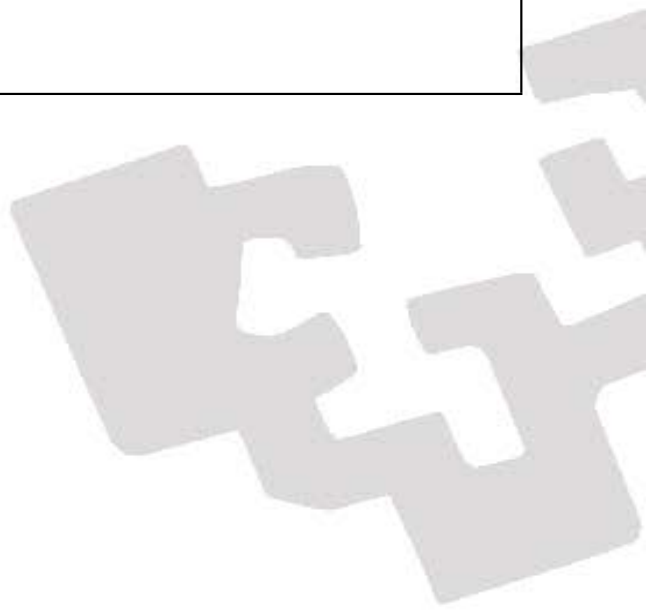

Matrices

Cómo definir una matriz

```
m3 <-  matrix(data =  1, nrow = 2, ncol = 2)
m3
```

```
     [,1] [,2]
[1,]    1    1
[2,]    1    1
```

Acceso a los elementos de una matriz

```
m3[2,1] <- 2
m3
```

```
     [,1] [,2]
[1,]    1    1
[2,]    2    1
```

Trasposición de una matriz

```
t(m3)
```

```
     [,1] [,2]
[1,]    1    2
[2,]    1    1
```

Matrices II

Cómo obtener la diagonal de una matriz

```
m3
```

```
     [,1] [,2]
[1,]    1    1
[2,]    2    1
```

```
diag(m3)
```

```
[1] 1 1
```

Cómo obtener la inversa de una matriz

```
m3
```

```
     [,1] [,2]
[1,]    1    1
[2,]    2    1
```

```
solve(m3)
```

```
     [,1] [,2]
[1,]   -1    1
[2,]    2   -1
```

Matrices III

```
m3
```

```
     [,1] [,2]
[1,]    1    1
[2,]    2    1
```

```
solve(m3)
```

```
     [,1] [,2]
[1,]   -1    1
[2,]    2   -1
```

Multiplicación de matrices

```
solve(m3) %*% m3
```

```
     [,1] [,2]
[1,]    1    0
[2,]    0    1
```

Multiplicación elemento a elemento

```
m3
```

```
     [,1] [,2]
[1,]    1    1
[2,]    2    1
```

```
solve(m3) * m3
```

```
     [,1] [,2]
[1,]   -1    1
[2,]    4   -1
```

Matrices IV

Cómo rellenar una matriz

```
xmat <- matrix(data = 1:6,
               nrow = 2,
               ncol = 3,
               byrow = FALSE)
xmat
```

```
     [,1] [,2] [,3]
[1,]    1    3    5
[2,]    2    4    6
```

```
xmat <- matrix(data = 1:6,
               nrow = 2,
               ncol = 3,
               byrow = TRUE)
xmat
```

```
     [,1] [,2] [,3]
[1,]    1    2    3
[2,]    4    5    6
```

Matrices V

Cómo acceder a diferentes partes de una matriz

```
xmat
```

```
     [,1] [,2] [,3]
[1,]    1    2    3
[2,]    4    5    6
```

Tercera columna

```
xmat[,3]
```

```
[1] 3 6
```

Primera fila

```
xmat[1,]
```

```
[1] 1 2 3
```

Matrices VI

Cómo eliminar diferentes partes una matriz

```
xmat
```

```
     [,1] [,2] [,3]
[1,]    1    2    3
[2,]    4    5    6
```

Eliminar la primera fila

```
xmat[-1,]
```

```
[1] 4 5 6
```

Eliminar la primera y segunda columna

```
xmat[,-c(1,2)]
```

```
[1] 3 6
```

Matrices VIIa

Uniendo matrices (o conjuntos de datos por filas y columnas)

```
m1 <- matrix(1, nr = 2, nc = 2)
m2 <- matrix(2, nr = 2, nc = 2)
m1
```

```
     [,1] [,2]
[1,]    1    1
[2,]    1    1
```

```
m2
```

```
     [,1] [,2]
[1,]    2    2
[2,]    2    2
```

```
rbind(m1, m2) # Unimos por filas
```

```
     [,1] [,2]
[1,]    1    1
[2,]    1    1
[3,]    2    2
[4,]    2    2
```

Matrices VIIb

Uniendo matrices (o conjuntos de datos por filas y columnas)

```
m1 <- matrix(1, nr = 2, nc = 2)
m2 <- matrix(2, nr = 2, nc = 2)
m1
```

```
     [,1] [,2]
[1,]    1    1
[2,]    1    1
```

```
m2
```

```
     [,1] [,2]
[1,]    2    2
[2,]    2    2
```

```
cbind(m1, m2) # Unimos por columnas
```

```
     [,1] [,2] [,3] [,4]
[1,]    1    1    2    2
[2,]    1    1    2    2
```

Funciones y bucles

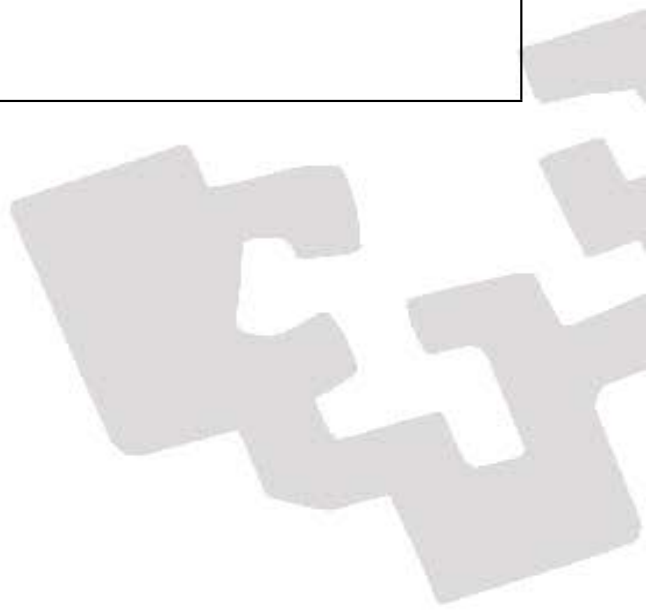

Funciones I

Definición

Una función es un conjunto de órdenes organizadas conjuntamente para ejecutar una acción determinada.

```
f.sum <- function(parameters){
                               out.sum <- sum(parameters)
                               return(out.sum)
                              }
```

```
 f.sum(2)
```

```
[1] 2
```

```
 f.sum(c(2,3,4,5))
```

```
[1] 14
```

Funciones II

Parámetros de una función

Los parámetros de una función se sustituyen por valores, por lo que cambiarlos dentro de la función no los cambia fuera de la función.

```
a <- 2
cat("a antes de la función:",a,"\n")
```

```
a antes de la función: 2
```

```
f.sum <- function(parameters){
                                a <- 3
                                cat("a dentro de la función:",a,"\n")
                                out.sum <- parameters + a
                                return(out.sum)
                                }
f.sum(2)
```

```
a dentro de la función: 3
[1] 5
```

```
cat("a después de la función:",a,"\n")
```

```
a después de la función: 2
```

Funciones III

Variables dentro de funciones I

Las variables definidas dentro de una función **no estarán disponibles** fuera de ella.

```
f.sum <- function(parameters){
                                b <- 3
                                cat("b inside the function:",b,"\n")
                                out.sum <- parameters + b
                                return(out.sum)
                                }
f.sum(2)
```

```
b inside the function: 3
```

```
[1] 5
```

```
cat("b after the function:",b,"\n")
```

```
Error in cat("b after the function:", b, "\n"): object 'b' not found
```

Funciones IV

Variables dentro de funciones II

Si utilizamos "«-", las variables definidas dentro de la función **estarán disponibles** fuera de ella.

```
f.sum <- function(parameters){
                                b <<- 3
                                cat("b dentro de la función:",b,"\n")
                                out.sum <- parameters + b
                                return(out.sum)
                                }
f.sum(2)
```

```
b dentro de la función: 3
```

```
[1] 5
```

```
cat("b después de la función:",b,"\n")
```

```
b después de la función: 3
```

Bucles I

Un bucle (loop) básico

```
  for(i in 1:3) {
                  cat("i:", i,"\n")  }
```

```
i: 1
i: 2
i: 3
```

Bucle anidado

```
mat = matrix(nrow=4,
             ncol=4)
  for(i in 1:4){
     for(j in 1:4){
                   mat[i,j] = i+j   }   }
mat
```

```
     [,1] [,2] [,3] [,4]
[1,]    2    3    4    5
[2,]    3    4    5    6
[3,]    4    5    6    7
[4,]    5    6    7    8
```

Bucles II

Los bucles son lentos

```
A <- matrix(1:(200*200),nrow=200, ncol=200,byrow=TRUE)
B <- matrix(             nrow=200, ncol=200           )
A[1:2,1:7]
```

```
     [,1] [,2] [,3] [,4] [,5] [,6] [,7]
[1,]    1    2    3    4    5    6    7
[2,]  201  202  203  204  205  206  207
```

Un bucle para una multiplicación de matrices B = A %*% A es lento

```
system.time(
   for (i in 1:200) {
       for (j in 1:200) {
           temp <- 0
           for (k in 1:200) {
                                temp   <-  temp + A[i,k]*A[k,j]  }
           B[i,j] <- temp }  }   )
```

```
   user  system elapsed
   0.71    0.00    0.70
```

Bucles III

Intenta evitar bucles

```
A <- matrix(1:(200*200),nrow=200, ncol=200,byrow=TRUE)
B <- matrix(             nrow=200, ncol=200           )
A[1:2,1:7]
```

```
     [,1] [,2] [,3] [,4] [,5] [,6] [,7]
[1,]    1    2    3    4    5    6    7
[2,]  201  202  203  204  205  206  207
```

Y, en su lugar, utiliza funciones internas para una multiplicación de matrices B = A %*% A, que son más rápidas

```
system.time(
            B <- A %*% A
           )
```

```
   user  system elapsed
      0       0       0
```

Evitando bucles

- Trabajando con matrices, podemos evitar bucles utizando las funciones **apply(M,1,fun)** o **apply(M, 2,fun)**
- Este comando aplica la función específica *fun*
  - a las filas de M, si toma el valor 1
  - a las columnas de M, si toma el valor 2

```
mat.A <- matrix(rep(1:3,3),3,3,byrow=TRUE)
mat.A
```

```
     [,1] [,2] [,3]
[1,]    1    2    3
[2,]    1    2    3
[3,]    1    2    3
```

Suma de filas utilizando **apply**

```
apply(mat.A, 1, sum)
```

```
[1] 6 6 6
```

Multiplicación de columnas utilizando **apply**

```
apply(mat.A, 2, prod)
```

```
[1]  1  8 27
```

Conjuntos de datos

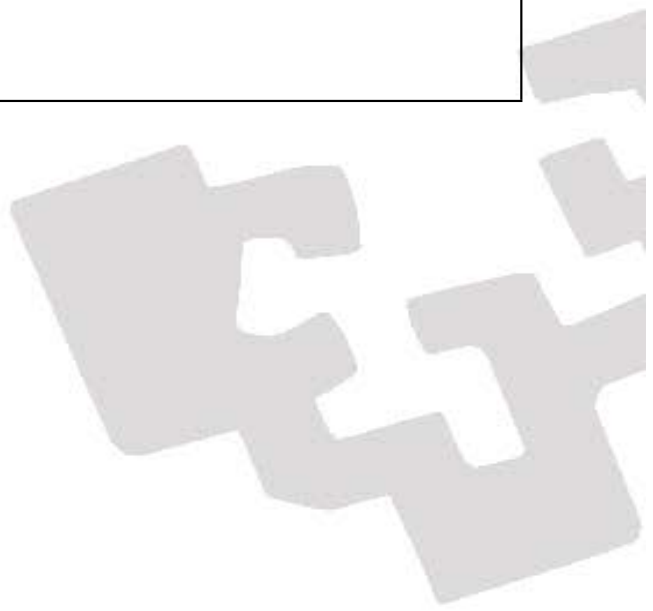

Data frames I

Los conjuntos de datos o *data frame* son estructuras bidimensionales de datos

```
employee.df <- data.frame("id"      = 101:104,
                          "age"     = c(34,23,19,28),
                          "Name"    = c("John",
                                        "Sara",
                                        "Rachel",
                                        "Arnold"))

employee.df
```

```
   id age   Name
1 101  34   John
2 102  23   Sara
3 103  19 Rachel
4 104  28 Arnold
```

Data frames II

Los conjuntos de datos puede ser tratados como matrices

```
employee.df
```

```
   id age   Name
1 101  34   John
2 102  23   Sara
3 103  19 Rachel
4 104  28 Arnold
```

```
employee.df[,c(1,3)]
```

```
   id   Name
1 101   John
2 102   Sara
3 103 Rachel
4 104 Arnold
```

```
employee.df[employee.df$id > 102,]
```

```
   id age   Name
3 103  19 Rachel
4 104  28 Arnold
```

Leyendo un archivo de datos

- Comprueba tu directorio de trabajo: getwd()
- En caso necesario, cambia tu directorio de trabajo: setwd("C:/...")
- Para leer un archivo de datos

```
mydata <- read.table("dataHeader.dat"          ,
                     header           = TRUE ,
                     stringsAsFactors = FALSE)
mydata
```

```
  id age   name
1  1  32 Amelia
2  2  54 Olivia
3  3  65   Jack
4  4  32  Harry
5  5  54 Sophia
```

Fin de la sesión

David Hoyos

Universidad del País Vasco (UPV/EHU)

Facultad de Economía y Empresa
Departmento de Economía Aplicada III (Econometría y Estadística)

Tel.: +34 94 601 7019
Email: david.hoyos@ehu.eus

http://www.ehu.eus/web/eephorad/david.hoyos

https://github.com/DabidH/Ekonometria